



UNIVERSIDAD DE MÁLAGA



Graduado en Ingeniería Informática

Detección de Enfermedades Neurodegenerativas en Imágenes de Resonancia Magnética

Detection of Neurodegenerative Diseases from Magnetic Resonance Images

Realizado por
Emilio Rodrigo Carreira Villalta

Tutorizado por
Miguel Ángel Molina Cabello
Ezequiel López Rubio

Departamento
Lenguajes y Ciencias de la Computación
UNIVERSIDAD DE MÁLAGA

MÁLAGA, junio de 2024



UNIVERSIDAD
DE MÁLAGA



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA
GRADUADO EN INGENIERÍA INFORMÁTICA

**Detección de Enfermedades Neurodegenerativas en Imágenes
de Resonancia Magnética**

**Detection of Neurodegenerative Diseases from Magnetic
Resonance Images**

Realizado por
Emilio Rodrigo Carreira Villalta

Tutorizado por
Miguel Ángel Molina Cabello
Ezequiel López Rubio

Departamento
Lenguajes y Ciencias de la Computación

UNIVERSIDAD DE MÁLAGA
MÁLAGA, JUNIO DE 2024

Fecha de defensa: julio de 2024

Abstract

This Final Degree Project (TFG) aims to design and develop an advanced system using computer vision and deep learning techniques for the detection of Multiple Sclerosis (MS) from magnetic resonance imaging (MRI) scans. The primary goal is to create an efficient tool that aids healthcare professionals in accurately identifying and classifying brain lesions caused by MS, enabling early diagnosis and tracking of the disease's progression.

The project will implement a YOLOv8 model, a state-of-the-art convolutional neural network (CNN) architecture, to perform automatic segmentation and detection of MS lesions in MRI scans. An extensive training process will be conducted using the Picasso supercomputer at the University of Málaga, allowing for high computational performance to optimize the model's accuracy. The training will leverage the MSSEG-2 dataset, which contains 3D brain scans from 92 patients across multiple time points. These 3D scans will be processed into 2D slices, enabling the triangulation of lesion locations across various planes for precise detection.

The dataset will be preprocessed to generate millions of 2D images, which will be used to train the YOLOv8 model on the Picasso supercomputer. By combining advanced computer vision techniques, a deep learning architecture, and large-scale data processing, this project aims to deliver a highly accurate system for the detection of Multiple Sclerosis, significantly improving the tools available to medical professionals in analyzing MRI data.

Keywords: MRI, Multiple Sclerosis, Picasso Supercomputer, YOLOv8, Computer Vision, CNN, Deep Learning

Resumen

Este Proyecto de Fin de Grado (TFG) tiene como objetivo diseñar y desarrollar un sistema avanzado utilizando técnicas de visión por computadora y aprendizaje profundo para la detección de Esclerosis Múltiple (EM) a partir de imágenes de resonancia magnética (IRM). El objetivo principal es crear una herramienta eficiente que ayude a los profesionales de la salud a identificar y clasificar con precisión las lesiones cerebrales causadas por la EM, permitiendo un diagnóstico temprano y el seguimiento de la progresión de la enfermedad.

El proyecto implementará un modelo YOLOv8, una arquitectura de red neuronal convolucional (CNN) de vanguardia, para realizar la segmentación y detección automáticas de las lesiones de EM en las imágenes de IRM. El sistema pasará por un extenso proceso de entrenamiento utilizando el superordenador Picasso de la Universidad de Málaga, lo que permitirá un alto rendimiento computacional para optimizar la precisión del modelo. El entrenamiento aprovechará el conjunto de datos MSSEG-2, que contiene escaneos cerebrales 3D de 92 pacientes en múltiples momentos. Estos escaneos 3D se procesarán en cortes 2D, lo que permitirá la triangulación de la ubicación de las lesiones a través de varios planos para una detección precisa.

El conjunto de datos se preprocesará para generar millones de imágenes 2D, que se utilizarán para entrenar el modelo YOLOv8 en el superordenador Picasso. Al combinar técnicas avanzadas de visión por computadora, una arquitectura de aprendizaje profundo y procesamiento de datos a gran escala, este proyecto tiene como objetivo entregar un sistema altamente preciso para la detección de Esclerosis Múltiple, mejorando significativamente las herramientas disponibles para los profesionales médicos en el análisis de datos de IRM.

Palabras clave: IRM, Esclerosis Múltiple, Superordenador Picasso, YOLOv8, Visión por Computador, CNN, Aprendizaje Profundo

Índice

1. Introducción	9
1.1. Motivación	9
1.2. Objetivos	9
1.3. Estructura del documento	9
1.4. Tecnologías usadas	9
2. Estado del Arte	11
2.1. Inteligencia artificial	11
2.2. Aprendizaje automático	12
2.3. Aprendizaje supervisado	13
2.4. Aprendizaje no supervisado	14
2.5. Aprendizaje profundo	15
2.5.1. Redes neuronales profundas	16
2.5.2. Redes neuronales convolucionales	16
3. Conjunto de Datos	17
3.1. MSLesSeg2024	17
3.2. Visualización de los datos	18
3.3. Tamaño del conjunto de datos	19
3.3.1. Secciones sobre los planos ortogonales	20
3.3.2. Secciones sobre planos arbitrarios	22
4. Conclusions and Futures Lines of Research	23
4.1. Conclusions	23
4.2. Future lines of Research	23
5. Conclusiones y Líneas Futuras	25
5.1. Conclusiones	25
5.2. Líneas Futuras	25

Índice de figuras

1.	Jerarquía Inteligencia Artificial [5]	12
2.	Aprendizaje Supervisado vs Aprendizaje no Supervisado [10]	13
3.	Visualización de cortes cerebrales con su máscara usando 3DSlicer [16]	18
4.	Visualización de las 3 proyecciones cerebrales	19

1

Introducción

1.1. Motivación

1.2. Objetivos

1.3. Estructura del documento

1.4. Tecnologías usadas

Estado del Arte

2.1. Inteligencia artificial

La inteligencia artificial (IA) es un campo de la informática que se centra en el desarrollo de sistemas y programas capaces de ejecutar tareas que normalmente requieren inteligencia humana, como el razonamiento, el aprendizaje, la percepción y la toma de decisiones [1]. Desde sus inicios en la década de 1950, la IA ha avanzado considerablemente gracias a las mejoras en los algoritmos, el aumento del poder de procesamiento y la disponibilidad de grandes volúmenes de datos. [2]

En el ámbito de la salud, la IA ha transformado diversos aspectos del diagnóstico, tratamiento y gestión médica. Los sistemas de IA pueden analizar imágenes médicas, como radiografías y resonancias magnéticas, lo que ayuda a los profesionales de la salud a detectar enfermedades de manera más rápida y precisa, mejorando la identificación temprana de condiciones críticas. Además, la IA permite procesar grandes volúmenes de datos clínicos para identificar patrones que pueden ser esenciales para la toma de decisiones médicas, así como personalizar tratamientos basados en el análisis de datos genómicos y de salud del paciente [3]. Asimismo, la automatización de tareas administrativas, como la programación de citas y la gestión de registros médicos, optimiza la eficiencia operativa en hospitales y clínicas. Por otro lado, los chatbots y asistentes virtuales mejoran la atención al paciente al ofrecer información médica y recordatorios de medicamentos, facilitando así el acceso a la atención médica. [4]

Estos avances en inteligencia artificial no solo están revolucionando la atención médica, sino que también están contribuyendo a mejorar la experiencia del paciente y la eficiencia de los sistemas de salud en general.




Figura 1: Jerarquía Inteligencia Artificial [5]

2.2. Aprendizaje automático

Tal y como se muestra en la figura 1, la inteligencia artificial engloba todos los sistemas contruidos por el hombre que son capaces de actuar de una forma inteligente, similar a la de los seres humanos. El aprendizaje automático, por su parte, se sitúa en un nivel superior, ya que es una subdisciplina de la IA que permite a los sistemas aprender y mejorar a partir de la experiencia sin ser programados explícitamente para cada tarea [6]. Este enfoque se basa en algoritmos que analizan datos, identifican patrones y hacen predicciones [7].

Entre los algoritmos más conocidos se encuentra la **regresión lineal**, que se utiliza para predecir valores continuos. Por ejemplo, puede estimar precios de viviendas en función de características como ubicación y tamaño. Otro algoritmo popular es el de **Máquinas de Soporte Vectorial (SVM)**, que es eficaz para tareas de clasificación y regresión, y tiene aplicaciones en el reconocimiento de imágenes y la detección de fraudes. Los **árboles de decisión** también son ampliamente utilizados; toman decisiones a través de una serie de preguntas de tipo "sí/no" se emplean en campos como la evaluación de riesgos y la selección de características en modelos predictivos [8].

El algoritmo de **K-Vecinos más Cercanos (K-NN)** se utiliza para clasificación y regresión al encontrar la cercanía entre datos, siendo útil en la recomendación de productos y la clasificación de documentos. Por último, aunque las **redes neuronales** son una parte fundamental del aprendizaje profundo, sus versiones más simples se emplean en tareas como la predicción de series temporales y la clasificación de datos.

Las aplicaciones del aprendizaje automático son diversas, abarcando desde la detección de spam en correos electrónicos hasta la predicción de enfermedades a partir de datos médicos [9]. La capacidad de estos algoritmos para procesar y aprender de grandes volúmenes de datos los convierte en herramientas valiosas en campos como la finanzas, la atención médica y el marketing. El aprendizaje automático no solo mejora la eficiencia de los procesos, sino que también permite a las organizaciones tomar decisiones más informadas basadas en datos.

2.3. Aprendizaje supervisado

El aprendizaje supervisado es una técnica dentro del aprendizaje automático que utiliza un conjunto de datos etiquetados para entrenar modelos. En este enfoque, se proporciona al modelo ejemplos de entrada junto con sus correspondientes salidas esperadas, lo que permite que el sistema aprenda a predecir resultados a partir de datos no vistos. Este método se utiliza comúnmente en tareas como la clasificación y la regresión, donde el objetivo es asignar una etiqueta a una entrada o predecir un valor continuo, respectivamente [6] [7].




Figura 2: Aprendizaje Supervisado vs Aprendizaje no Supervisado [10]

Entre los algoritmos más populares en este campo se encuentran la regresión logística tal y como se puede observar en la parte izquierda de la figura 2, los árboles de decisión y las máquinas de soporte vectorial (SVM). Por ejemplo, la regresión logística es frecuentemente utilizada para problemas de clasificación binaria, mientras que los árboles de decisión son valiosos para interpretar modelos y realizar decisiones basadas en datos categóricos.

El aprendizaje supervisado ha encontrado aplicaciones en diversas áreas, incluyendo la detección de fraudes en transacciones financieras, el análisis de sentimientos en redes sociales y el diagnóstico médico a partir de imágenes [8] [9]. Además, el avance en la disponibilidad de datos y el poder computacional ha permitido el desarrollo de modelos cada vez más sofisticados que mejoran su precisión y eficiencia. Este enfoque ha demostrado ser fundamental para el desarrollo de sistemas de inteligencia artificial que requieren un aprendizaje previo a partir de datos etiquetados.

2.4. Aprendizaje no supervisado

El aprendizaje no supervisado es otra técnica dentro del aprendizaje automático que se centra en encontrar patrones y estructuras ocultas en conjuntos de datos no etiquetados. A diferencia del aprendizaje supervisado, donde se proporcionan ejemplos de entrada junto con sus salidas esperadas, en el aprendizaje no supervisado el modelo debe aprender de los datos sin ninguna guía explícita sobre qué buscar. Este enfoque es particularmente útil en situaciones donde no se dispone de etiquetas o cuando se quiere explorar la naturaleza subyacente de los datos [9] [7].

Entre los algoritmos más comunes en el aprendizaje no supervisado se encuentran el análisis de conglomerados (clustering) tal y como se puede observar en la parte derecha de la figura 2, la reducción de dimensionalidad y la asociación. Por ejemplo, el análisis de conglomerados se utiliza para agrupar datos en conjuntos similares, lo que puede ser útil en la segmentación de mercados o en la organización de grandes volúmenes de información. Por otro lado, técnicas como el Análisis de Componentes Principales (PCA) se emplean para reducir la cantidad de variables en un conjunto de datos mientras se preserva la mayor parte de la variabilidad de los datos originales [8] [6].

El aprendizaje no supervisado tiene diversas aplicaciones, que incluyen la segmentación de clientes en marketing, la identificación de patrones de comportamiento en redes sociales

y la detección de anomalías en sistemas de seguridad. A medida que la cantidad de datos disponibles sigue creciendo, las técnicas de aprendizaje no supervisado se vuelven cada vez más relevantes, permitiendo a los investigadores y profesionales descubrir información valiosa sin la necesidad de datos etiquetados.

2.5. Aprendizaje profundo

El aprendizaje profundo es una subárea del aprendizaje automático que se basa en redes neuronales artificiales con muchas capas, conocidas como redes neuronales profundas. A diferencia de los algoritmos tradicionales de aprendizaje automático, que a menudo requieren la extracción manual de características, el aprendizaje profundo puede aprender representaciones jerárquicas de los datos, permitiendo al modelo descubrir patrones complejos de manera autónoma [11].

Este enfoque ha sido particularmente exitoso en áreas como el reconocimiento de imágenes, el procesamiento del lenguaje natural y el aprendizaje por refuerzo. En el reconocimiento de imágenes, por ejemplo, las redes neuronales convolucionales (CNNs) permiten identificar características como bordes, texturas y formas, logrando resultados sobresalientes en tareas de clasificación de imágenes. Asimismo, en el procesamiento del lenguaje natural, las redes neuronales recurrentes (RNNs) y sus variantes, como las redes de memoria a largo plazo (LSTM), han mejorado significativamente el rendimiento en tareas como la traducción automática y el análisis de sentimientos [12] [13].

El aprendizaje profundo es muy dependiente de grandes cantidades de datos y potencia computacional, lo que lo hace particularmente adecuado para aplicaciones en las que se dispone de estos recursos, como en grandes empresas tecnológicas o en el campo de la investigación científica. Sin embargo, su capacidad para generalizar en escenarios con menos datos o en contextos que difieren de los datos de entrenamiento sigue siendo un desafío abierto. A pesar de ello, la innovación en arquitecturas de redes neuronales y técnicas de optimización ha permitido avances importantes en el rendimiento y la eficiencia de los modelos de aprendizaje profundo [14].

2.5.1. Redes neuronales profundas

2.5.2. Redes neuronales convolucionales

Conjunto de Datos

3.1. MSLesSeg2024

El conjunto de datos MSLesSeg se presenta como una herramienta fundamental en la investigación sobre segmentación de lesiones en imágenes médicas, particularmente en resonancias magnéticas. Este recurso comprende aproximadamente 1,200 imágenes, que representan una variedad de patologías y características anatómicas, siendo crucial para la creación y evaluación de algoritmos en el ámbito del aprendizaje automático y la visión por computadora. Cada imagen viene acompañada de máscaras de segmentación que delimitan las áreas de interés, lo que permite a los investigadores entrenar modelos capaces de detectar y clasificar lesiones con mayor precisión. Además, MSLesSeg facilita la comparación de diferentes metodologías y enfoques dentro de la segmentación médica, impulsando el progreso en la automatización del diagnóstico y tratamiento de enfermedades. Este conjunto de datos ha sido utilizado en múltiples estudios y competiciones, estableciendo un referente en la comunidad de imágenes médicas. [15]

Para este proyecto, utilizaremos el conjunto de datos MSLesSeg2024, que se empleó en una competición organizada entre diversas universidades reconocidas. El objetivo de esta competición era desarrollar un sistema capaz de predecir de manera efectiva la esclerosis lateral múltiple. El conjunto de datos está compuesto por información de escáneres de resonancia magnética de 90 pacientes, recogida en distintos momentos temporales. La parte destinada al entrenamiento de los modelos incluye máscaras elaboradas por expertos en patologías cerebrales, junto con sus correspondientes anotaciones.

3.2. Visualización de los datos

El objetivo de este proyecto es entrenar un sistema de visión por computador preentrenado para detectar esclerosis lateral múltiple en escáneres de resonancia magnética. Sin embargo, este conjunto de datos presenta una peculiaridad que convierte el proyecto en un verdadero desafío de procesamiento de datos, el cual abordaremos en capítulos posteriores bajo el concepto de explotación de ingentes cantidades de datos.

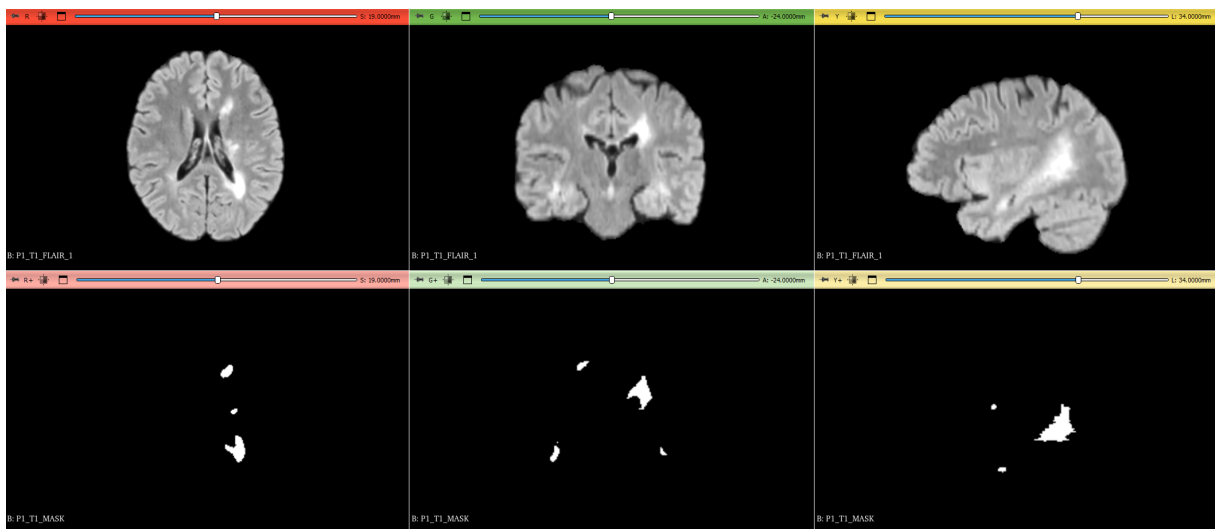


Figura 3: Visualización de cortes cerebrales con su máscara usando 3DSlicer [16]

Cada uno de estos escáneres de resonancia magnética contiene datos de imagen volumétrica tridimensional, representados como matrices tridimensionales de valores de intensidad, junto con metadatos que describen la estructura y el contexto de las imágenes. Debido a esta complejidad, una persona no puede simplemente abrir el archivo y visualizar la representación tridimensional del cerebro. Existen diversas herramientas de software especializadas en la visualización de estas matrices de imágenes. He utilizado 3DSlicer para estudiar y comprender el conjunto de datos, ya que permite visualizar los diferentes cortes cerebrales y ajustar los parámetros, como se puede observar en la figura 3 [16] [17].

3.3. Tamaño del conjunto de datos

Como se menciona en el resumen del proyecto, utilizaremos el supercomputador Picasso de la Universidad de Málaga para entrenar el modelo con el conjunto de datos. La justificación para emplear un superordenador en esta tarea se fundamenta en las grandes dimensiones del conjunto de datos a procesar. En este caso, se utilizará únicamente la carpeta de entrenamiento, mientras que se desechará la de test. Esta decisión se debe a que la carpeta de test no incluye la máscara, ya que este conjunto de datos fue empleado en una competición, y su exclusión garantizaba la equidad del evento [18].

Todos los modelos de YOLO desarrollados por Ultralytics han sido preentrenados para detectar patrones y formas en imágenes bidimensionales (2D). Sin embargo, no es posible utilizar directamente un formato matricial tridimensional (3D) para realizar inferencias con estos modelos. Para abordar esta limitación, la estrategia consiste en realizar cortes bidimensionales (2D) de las imágenes tridimensionales (3D) en diferentes planos. Esto permitirá extraer secciones relevantes de la imagen 3D y convertirlas en representaciones 2D que el modelo pueda procesar eficazmente. Al aplicar esta técnica, se espera mejorar la precisión en la detección y el análisis de características específicas dentro de los volúmenes tridimensionales [19].

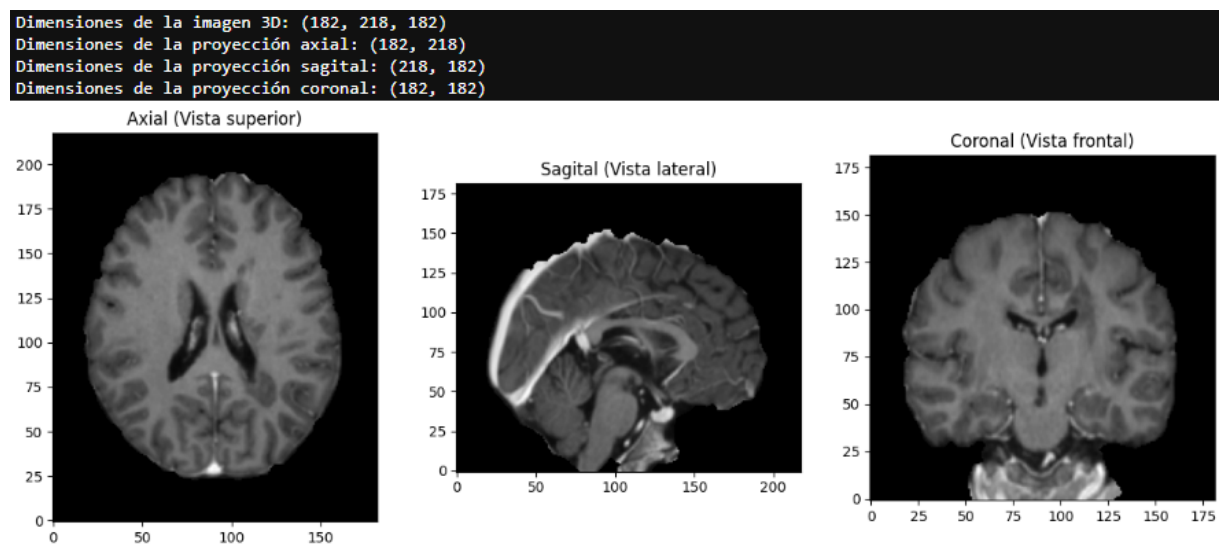


Figura 4: Visualización de las 3 proyecciones cerebrales

3.3.1. Secciones sobre los planos ortogonales

En última instancia, se utilizará el supercomputador Picasso para entrenar el modelo más voluminoso disponible en la biblioteca con el conjunto de datos completo. Sin embargo, para realizar pruebas en un entorno más convencional, se elige un enfoque que reduce la complejidad computacional del conjunto de datos. En primer lugar, se opta por obtener diversas secciones bidimensionales (2D) del cerebro mediante cortes a lo largo de los planos ortogonales, es decir, aquellos que son paralelos a los ejes X, Y y Z. De esta manera, obtenemos las vistas coronal, sagital y axial del cerebro tal como se observa en la figura 4.

Cada una de estas matrices tridimensionales, como se puede observar en la parte superior de la figura 4, cuenta con un número específico de cortes. Esta información será muy útil para calcular el tamaño total de nuestro conjunto de datos. El número de imágenes que extraeremos de un único escáner cerebral se determinará sumando los cortes en cada una de las proyecciones:

$$n_{\text{cortes}} = n_{\text{axiales}} + n_{\text{sagitales}} + n_{\text{coronales}} = 182 + 218 + 182 = 582 \text{ imágenes}$$

Otro aspecto muy importante y que aún no se ha comentado es que por cada uno de los escáneres de un paciente, se realizan tres tipos de escáneres distintos: el FLAIR, el T1 y el T2. Cada uno de estos tipos de escaneo ofrece una perspectiva única y complementaria sobre la anatomía y la fisiología del cerebro, permitiendo a los médicos realizar un diagnóstico más preciso y completo.

El escáner FLAIR es especialmente útil para detectar lesiones en la sustancia blanca del cerebro, ya que suprime la señal del líquido cefalorraquídeo, lo que permite visualizar mejor las anomalías que de otro modo podrían quedar ocultas. Esta secuencia es fundamental en el diagnóstico de condiciones como la esclerosis múltiple, donde las placas o lesiones pueden ser difíciles de observar en otras secuencias [20]. Además, FLAIR es eficaz en la identificación de cambios sutiles en el tejido cerebral, como la inflamación o el edema, que pueden ser indicativos de procesos patológicos.

Por otro lado, el escáner T1 proporciona imágenes que son excepcionales para evaluar la anatomía cerebral. Esta secuencia permite distinguir entre los diferentes tipos de tejidos, ya que el contraste en las imágenes T1 es más marcado. Por ejemplo, el tejido graso se destaca claramente, lo que facilita la visualización de estructuras como la corteza cerebral y los núcleos

basales [21]. Además, cuando se utiliza un medio de contraste, las imágenes T1 pueden resaltar tumores o lesiones vasculares, mejorando significativamente la capacidad diagnóstica.

Finalmente, el escáner T2 se utiliza para resaltar la presencia de líquido en el cerebro. Las áreas con mayor contenido de agua, como edemas o lesiones hemorrágicas, aparecen brillantes en las imágenes T2 [22]. Esta secuencia es particularmente valiosa para detectar trastornos como accidentes cerebrovasculares, tumores y condiciones neurodegenerativas. La combinación de T2 con T1 y FLAIR permite a los neurólogos obtener un panorama más completo de la salud cerebral del paciente, ya que cada secuencia resalta diferentes características y patologías.

La razón para realizar múltiples escaneos en un mismo paciente radica en la complejidad del cerebro y la diversidad de patologías que pueden presentarse. La información obtenida a partir de cada tipo de escaneo se integra para ofrecer una visión holística del estado del cerebro, lo que facilita un diagnóstico más preciso y un mejor plan de tratamiento. En resumen, la combinación de las secuencias FLAIR, T1 y T2 en la resonancia magnética cerebral es esencial para proporcionar una evaluación integral y detallada, asegurando que se detecten y se manejen adecuadamente las diversas condiciones que pueden afectar al sistema nervioso central [23] [24].

El hecho de que sea necesario procesar tres tipos de escáneres cada vez que un paciente se somete a una resonancia magnética triplica el número total de imágenes que se deben analizar por paciente y en un momento determinado.

$$N_{\text{cortes}} = n_{\text{cortes}} * 3 = 1746 \text{ imágenes}$$

Una vez que se obtiene el número total de imágenes, procesaremos cada uno de los escáneres de resonancia presentes en el conjunto de datos. Para calcular el total de imágenes a procesar, solo es necesario multiplicar ese número por el total de escáneres en el dataset. Mediante una sencilla ecuación que se puede implementar en una función que gestione carpetas y archivos, es posible obtener este resultado:

$$N_{\text{escáneres}} = \sum_{i=0}^n P(i) = 92 \text{ escáneres}$$

$$N_{\text{imágenes}} = N_{\text{escáneres}} * N_{\text{cortes}} = 160,632 \text{ imágenes}$$

A continuación, se detalla la estructura que debe tener el conjunto de datos procesado para entrenar un modelo YOLO. Sin embargo, es importante destacar que, para cada imagen

del conjunto de datos, debe existir un archivo de texto correspondiente. Este archivo debe contener las coordenadas que indican las áreas donde, según las anotaciones del experto, se presenta esclerosis.

$$TAM_{\text{dataset}} = N_{\text{imágenes}} + N_{\text{anotaciones}} = 2 * N_{\text{imágenes}} = 321,264 \text{ archivos}$$

3.3.2. Secciones sobre planos arbitrarios

4

Conclusions and Futures Lines of Research

4.1. Conclusions

4.2. Future lines of Research

5

Conclusiones y Líneas Futuras

5.1. Conclusiones

5.2. Líneas Futuras

Referencias

- [1] Techopedia. “¿Qué es la inteligencia artificial?” En: (2024). Accedido el 7 de octubre de 2024. URL: <https://www.techopedia.com/definition/1905/artificial-intelligence-ai>.
- [2] Wikipedia. “Inteligencia artificial”. En: (2024). Accedido el 7 de octubre de 2024. URL: https://es.wikipedia.org/wiki/Inteligencia_artificial.
- [3] Salesforce. “Comprender la inteligencia artificial: definición, tipos, casos de uso y desafíos”. En: (2021). Accedido el 7 de octubre de 2024. URL: <https://www.salesforce.com/es/blogs/2021/01/ai-healthcare.html>.
- [4] TechCrunch. “The impact of AI on healthcare”. En: (2021). Accedido el 7 de octubre de 2024. URL: <https://techcrunch.com/2021/06/12/the-impact-of-ai-on-healthcare/>.
- [5] *Diagrama sobre Inteligencia Artificial y Machine Learning*. Imagen recuperada de DuckDuckGo. 2020. URL: <https://www.duacode.com/data/blog/106/images/215/4.jpg?t=20201112>.
- [6] E. Alpaydin. *Introduction to Machine Learning*. 4th. MIT Press, 2020. URL: <https://mitpress.mit.edu/9780262033848/introduction-to-machine-learning/>.
- [7] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006. URL: <https://www.springer.com/gp/book/9780387310732>.
- [8] T. M. Mitchell. *Machine Learning*. McGraw-Hill, 1997. URL: <https://www.cs.cmu.edu/~tom/10701/slides/mitchell-ml-book-1997.pdf>.
- [9] J. D. Kelleher y B. Tierney. *Data Science: A Practical Introduction to Data Science*. M4W Press, 2018. URL: <https://www.m4wpress.com/books/data-science-a-practical-introduction-to-data-science>.
- [10] Imagen sin autor. *Aprendizaje Supervisado vs No Supervisado*. Accedido el 7 de octubre de 2024. 2024. URL: https://lh3.googleusercontent.com/-q3LXeJu275Q/YEzXbCDgc_I/AAAAAAAAxN0/mFU2-qIuuEcQpxaMTTnUOMCn4vZ4or_eQCLcBGAsYHQ/w640-h254/image.png.

- [11] Aaron Courville Ian Goodfellow Yoshua Bengio. *Deep Learning*. MIT Press, 2016.
- [12] Yann LeCun y Geoffrey Bengio Yoshua y Hinton. *Deep Learning*. doi:10.1038/nature14539. 2015.
- [13] Geoffrey Hinton. *A Practical Guide to Training Restricted Boltzmann Machines*. Accedido el 7 de octubre de 2024. 2012. URL: <https://www.cs.toronto.edu/~hinton/absps/guideTR.pdf>.
- [14] Alex Krizhevsky, Ilya Sutskever y Geoffrey Hinton. *ImageNet Classification with Deep Convolutional Neural Networks*. Accedido el 7 de octubre de 2024. 2012. URL: <https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf>.
- [15] B. R. P. M. R. M. Jorge et al. *MSLesSeg: A Medical Dataset for Lesion Segmentation*. Accedido el 9 de octubre de 2024. 2024. URL: <https://iplab.dmi.unict.it/mfs/ms-les-seg/#home>.
- [16] Andrey Fedorov et al. *3D Slicer: An Open Source Software Platform for Medical Image Informatics, Image Processing, and 3D Visualization*. Accedido el 9 de octubre de 2024. 2023. URL: <https://www.slicer.org>.
- [17] Neuroimaging Informatics Technology Initiative. *NIfTI-1.1 Specification*. Accedido el 9 de octubre de 2024. 2021. URL: <https://nifti.nimh.nih.gov/nifti-1/>.
- [18] Centro de Computación Científica de Málaga. *Picasso: Supercomputador del Centro de Computación Científica de Málaga*. Accedido el 9 de octubre de 2024. 2024. URL: <https://www.res.es/es/nodos-de-la-res/picasso>.
- [19] Greg Jocher y et al. *Ultralytics YOLO: State-of-the-art Object Detection and Segmentation*. Accedido el 9 de octubre de 2024. 2023. URL: <https://github.com/ultralytics/yolov5>.
- [20] M. Brant-Zawadzki y et al. "Fluid-Attenuated Inversion Recovery (FLAIR): A New Method for Imaging Cerebrospinal Fluid". En: *AJNR American Journal of Neuroradiology* 13.2 (1992), págs. 297-303.
- [21] J. P. Klein y et al. "MRI of the Brain: Techniques and Applications". En: *Clinical Radiology* 72.11 (2017), págs. 895-903.

- [22] A. Kumar y A. Choudhury. “Understanding MRI: T1 and T2 Relaxation”. En: *Radiology Essentials for Medical Students* (2020).
- [23] A. G. Osborn y R. Goodkin. *Diagnostic Imaging: Brain*. Elsevier, 2017.
- [24] Mayo Clinic. *Magnetic Resonance Imaging (MRI) of the Brain*. Accedido el 9 de octubre de 2024. URL: <https://www.mayoclinic.org/tests-procedures/magnetic-resonance-imaging/about/pac-20384945>.

Apéndice A

Manual de Instalación