



UNIVERSIDAD DE MÁLAGA



Graduado en Ingeniería Informática

## Detección de Enfermedades Neurodegenerativas en Imágenes de Resonancia Magnética

## Detection of Neurodegenerative Diseases from Magnetic Resonance Images

Realizado por  
Emilio Rodrigo Carreira Villalta

Tutorizado por  
Miguel Ángel Molina Cabello  
Ezequiel López Rubio

Departamento  
Lenguajes y Ciencias de la Computación  
UNIVERSIDAD DE MÁLAGA

MÁLAGA, junio de 2024



UNIVERSIDAD  
DE MÁLAGA



**ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA**  
**GRADUADO EN INGENIERÍA INFORMÁTICA**

**Detección de Enfermedades Neurodegenerativas en Imágenes  
de Resonancia Magnética**

**Detection of Neurodegenerative Diseases from Magnetic  
Resonance Images**

Realizado por  
**Emilio Rodrigo Carreira Villalta**

Tutorizado por  
**Miguel Ángel Molina Cabello**  
**Ezequiel López Rubio**

Departamento  
**Lenguajes y Ciencias de la Computación**

**UNIVERSIDAD DE MÁLAGA**  
**MÁLAGA, JUNIO DE 2024**

Fecha de defensa: julio de 2024

# Abstract

This Final Degree Project (TFG) aims to design and develop an advanced system using computer vision and deep learning techniques for the detection of Multiple Sclerosis (MS) from magnetic resonance imaging (MRI) scans. The primary goal is to create an efficient tool that aids healthcare professionals in accurately identifying and classifying brain lesions caused by MS, enabling early diagnosis and tracking of the disease's progression.

The project will implement a YOLOv8 model, a state-of-the-art convolutional neural network (CNN) architecture, to perform automatic segmentation and detection of MS lesions in MRI scans. An extensive training process will be conducted using the Picasso supercomputer at the University of Málaga, allowing for high computational performance to optimize the model's accuracy. The training will leverage the MSSEG-2 dataset, which contains 3D brain scans from 92 patients across multiple time points. These 3D scans will be processed into 2D slices, enabling the triangulation of lesion locations across various planes for precise detection.

The dataset will be preprocessed to generate millions of 2D images, which will be used to train the YOLOv8 model on the Picasso supercomputer. By combining advanced computer vision techniques, a deep learning architecture, and large-scale data processing, this project aims to deliver a highly accurate system for the detection of Multiple Sclerosis, significantly improving the tools available to medical professionals in analyzing MRI data.

**Keywords:** MRI, Multiple Sclerosis, Picasso Supercomputer, YOLOv8, Computer Vision, CNN, Deep Learning

# Resumen

Este Proyecto de Fin de Grado (TFG) tiene como objetivo diseñar y desarrollar un sistema avanzado utilizando técnicas de visión por computadora y aprendizaje profundo para la detección de Esclerosis Múltiple (EM) a partir de imágenes de resonancia magnética (IRM). El objetivo principal es crear una herramienta eficiente que ayude a los profesionales de la salud a identificar y clasificar con precisión las lesiones cerebrales causadas por la EM, permitiendo un diagnóstico temprano y el seguimiento de la progresión de la enfermedad.

El proyecto implementará un modelo YOLOv8, una arquitectura de red neuronal convolucional (CNN) de vanguardia, para realizar la segmentación y detección automáticas de las lesiones de EM en las imágenes de IRM. El sistema pasará por un extenso proceso de entrenamiento utilizando el superordenador Picasso de la Universidad de Málaga, lo que permitirá un alto rendimiento computacional para optimizar la precisión del modelo. El entrenamiento aprovechará el conjunto de datos MSSEG-2, que contiene escaneos cerebrales 3D de 92 pacientes en múltiples momentos. Estos escaneos 3D se procesarán en cortes 2D, lo que permitirá la triangulación de la ubicación de las lesiones a través de varios planos para una detección precisa.

El conjunto de datos se preprocesará para generar millones de imágenes 2D, que se utilizarán para entrenar el modelo YOLOv8 en el superordenador Picasso. Al combinar técnicas avanzadas de visión por computadora, una arquitectura de aprendizaje profundo y procesamiento de datos a gran escala, este proyecto tiene como objetivo entregar un sistema altamente preciso para la detección de Esclerosis Múltiple, mejorando significativamente las herramientas disponibles para los profesionales médicos en el análisis de datos de IRM.

**Palabras clave:** IRM, Esclerosis Múltiple, Superordenador Picasso, YOLOv8, Visión por Computador, CNN, Aprendizaje Profundo



# Índice

<b>1. Introducción</b>	<b>9</b>
1.1. Motivación . . . . .	9
1.2. Objetivos . . . . .	9
1.3. Estructura del documento . . . . .	9
1.4. Tecnologías usadas . . . . .	9
<b>2. Estado del Arte</b>	<b>11</b>
2.1. Inteligencia Artificial . . . . .	11
2.2. Aprendizaje Automático . . . . .	12
2.3. Aprendizaje Supervisado . . . . .	13
2.4. Aprendizaje No Supervisado . . . . .	14
2.5. Aprendizaje Profundo . . . . .	15
2.5.1. Redes Neuronales Profundas . . . . .	16
2.5.2. Redes Neuronales Convolucionales . . . . .	16
<b>3. Conclusions and Futures Lines of Research</b>	<b>17</b>
3.1. Conclusions . . . . .	17
3.2. Future lines of Research . . . . .	17
<b>4. Conclusiones y Líneas Futuras</b>	<b>19</b>
4.1. Conclusiones . . . . .	19
4.2. Líneas Futuras . . . . .	19
<b>Apéndice A. Manual de Instalación</b>	<b>23</b>



# Índice de figuras

1.	Jerarquía Inteligencia Artificial [5] . . . . .	12
2.	Aprendizaje Supervisado vs Aprendizaje no Supervisado [10] . . . . .	13





# 1

# Introducción

**1.1. Motivación**

**1.2. Objetivos**

**1.3. Estructura del documento**

**1.4. Tecnologías usadas**



# Estado del Arte

## 2.1. Inteligencia Artificial

La inteligencia artificial (IA) es un campo de la informática que se centra en el desarrollo de sistemas y programas capaces de ejecutar tareas que normalmente requieren inteligencia humana, como el razonamiento, el aprendizaje, la percepción y la toma de decisiones [1]. Desde sus inicios en la década de 1950, la IA ha avanzado considerablemente gracias a las mejoras en los algoritmos, el aumento del poder de procesamiento y la disponibilidad de grandes volúmenes de datos. [2]

En el ámbito de la salud, la IA ha transformado diversos aspectos del diagnóstico, tratamiento y gestión médica. Los sistemas de IA pueden analizar imágenes médicas, como radiografías y resonancias magnéticas, lo que ayuda a los profesionales de la salud a detectar enfermedades de manera más rápida y precisa, mejorando la identificación temprana de condiciones críticas. Además, la IA permite procesar grandes volúmenes de datos clínicos para identificar patrones que pueden ser esenciales para la toma de decisiones médicas, así como personalizar tratamientos basados en el análisis de datos genómicos y de salud del paciente [3]. Asimismo, la automatización de tareas administrativas, como la programación de citas y la gestión de registros médicos, optimiza la eficiencia operativa en hospitales y clínicas. Por otro lado, los chatbots y asistentes virtuales mejoran la atención al paciente al ofrecer información médica y recordatorios de medicamentos, facilitando así el acceso a la atención médica. [4]

Estos avances en inteligencia artificial no solo están revolucionando la atención médica, sino que también están contribuyendo a mejorar la experiencia del paciente y la eficiencia de los sistemas de salud en general.




Figura 1: Jerarquía Inteligencia Artificial [5]

## 2.2. Aprendizaje Automático

Tal y como se muestra en la figura 1, la inteligencia artificial engloba todos los sistemas contruidos por el hombre que son capaces de actuar de una forma inteligente, similar a la de los seres humanos. El aprendizaje automático, por su parte, se sitúa en un nivel superior, ya que es una subdisciplina de la IA que permite a los sistemas aprender y mejorar a partir de la experiencia sin ser programados explícitamente para cada tarea [6]. Este enfoque se basa en algoritmos que analizan datos, identifican patrones y hacen predicciones [7].

Entre los algoritmos más conocidos se encuentra la **regresión lineal**, que se utiliza para predecir valores continuos. Por ejemplo, puede estimar precios de viviendas en función de características como ubicación y tamaño. Otro algoritmo popular es el de **Máquinas de Soporte Vectorial (SVM)**, que es eficaz para tareas de clasificación y regresión, y tiene aplicaciones en el reconocimiento de imágenes y la detección de fraudes. Los **árboles de decisión** también son ampliamente utilizados; toman decisiones a través de una serie de preguntas de tipo "sí/no" se emplean en campos como la evaluación de riesgos y la selección de características en modelos predictivos [8].

El algoritmo de **K-Vecinos más Cercanos (K-NN)** se utiliza para clasificación y regresión al encontrar la cercanía entre datos, siendo útil en la recomendación de productos y la clasificación de documentos. Por último, aunque las **redes neuronales** son una parte fundamental del aprendizaje profundo, sus versiones más simples se emplean en tareas como la predicción de series temporales y la clasificación de datos.

Las aplicaciones del aprendizaje automático son diversas, abarcando desde la detección de spam en correos electrónicos hasta la predicción de enfermedades a partir de datos médicos [9]. La capacidad de estos algoritmos para procesar y aprender de grandes volúmenes de datos los convierte en herramientas valiosas en campos como la finanzas, la atención médica y el marketing. El aprendizaje automático no solo mejora la eficiencia de los procesos, sino que también permite a las organizaciones tomar decisiones más informadas basadas en datos.

### 2.3. Aprendizaje Supervisado

El aprendizaje supervisado es una técnica dentro del aprendizaje automático que utiliza un conjunto de datos etiquetados para entrenar modelos. En este enfoque, se proporciona al modelo ejemplos de entrada junto con sus correspondientes salidas esperadas, lo que permite que el sistema aprenda a predecir resultados a partir de datos no vistos. Este método se utiliza comúnmente en tareas como la clasificación y la regresión, donde el objetivo es asignar una etiqueta a una entrada o predecir un valor continuo, respectivamente [6] [7].




Figura 2: Aprendizaje Supervisado vs Aprendizaje no Supervisado [10]

Entre los algoritmos más populares en este campo se encuentran la regresión logística tal y como se puede observar en la parte izquierda de la figura 2, los árboles de decisión y las máquinas de soporte vectorial (SVM). Por ejemplo, la regresión logística es frecuentemente utilizada para problemas de clasificación binaria, mientras que los árboles de decisión son valiosos para interpretar modelos y realizar decisiones basadas en datos categóricos.

El aprendizaje supervisado ha encontrado aplicaciones en diversas áreas, incluyendo la detección de fraudes en transacciones financieras, el análisis de sentimientos en redes sociales y el diagnóstico médico a partir de imágenes [8] [9]. Además, el avance en la disponibilidad de datos y el poder computacional ha permitido el desarrollo de modelos cada vez más sofisticados que mejoran su precisión y eficiencia. Este enfoque ha demostrado ser fundamental para el desarrollo de sistemas de inteligencia artificial que requieren un aprendizaje previo a partir de datos etiquetados.

## **2.4. Aprendizaje No Supervisado**

El aprendizaje no supervisado es otra técnica dentro del aprendizaje automático que se centra en encontrar patrones y estructuras ocultas en conjuntos de datos no etiquetados. A diferencia del aprendizaje supervisado, donde se proporcionan ejemplos de entrada junto con sus salidas esperadas, en el aprendizaje no supervisado el modelo debe aprender de los datos sin ninguna guía explícita sobre qué buscar. Este enfoque es particularmente útil en situaciones donde no se dispone de etiquetas o cuando se quiere explorar la naturaleza subyacente de los datos [9] [7].

Entre los algoritmos más comunes en el aprendizaje no supervisado se encuentran el análisis de conglomerados (clustering) tal y como se puede observar en la parte derecha de la figura 2, la reducción de dimensionalidad y la asociación. Por ejemplo, el análisis de conglomerados se utiliza para agrupar datos en conjuntos similares, lo que puede ser útil en la segmentación de mercados o en la organización de grandes volúmenes de información. Por otro lado, técnicas como el Análisis de Componentes Principales (PCA) se emplean para reducir la cantidad de variables en un conjunto de datos mientras se preserva la mayor parte de la variabilidad de los datos originales [8] [6].

El aprendizaje no supervisado tiene diversas aplicaciones, que incluyen la segmentación de clientes en marketing, la identificación de patrones de comportamiento en redes sociales

y la detección de anomalías en sistemas de seguridad. A medida que la cantidad de datos disponibles sigue creciendo, las técnicas de aprendizaje no supervisado se vuelven cada vez más relevantes, permitiendo a los investigadores y profesionales descubrir información valiosa sin la necesidad de datos etiquetados.

## 2.5. Aprendizaje Profundo

El aprendizaje profundo es una subárea del aprendizaje automático que se basa en redes neuronales artificiales con muchas capas, conocidas como redes neuronales profundas. A diferencia de los algoritmos tradicionales de aprendizaje automático, que a menudo requieren la extracción manual de características, el aprendizaje profundo puede aprender representaciones jerárquicas de los datos, permitiendo al modelo descubrir patrones complejos de manera autónoma [11].

Este enfoque ha sido particularmente exitoso en áreas como el reconocimiento de imágenes, el procesamiento del lenguaje natural y el aprendizaje por refuerzo. En el reconocimiento de imágenes, por ejemplo, las redes neuronales convolucionales (CNNs) permiten identificar características como bordes, texturas y formas, logrando resultados sobresalientes en tareas de clasificación de imágenes. Asimismo, en el procesamiento del lenguaje natural, las redes neuronales recurrentes (RNNs) y sus variantes, como las redes de memoria a largo plazo (LSTM), han mejorado significativamente el rendimiento en tareas como la traducción automática y el análisis de sentimientos [12] [13].

El aprendizaje profundo es muy dependiente de grandes cantidades de datos y potencia computacional, lo que lo hace particularmente adecuado para aplicaciones en las que se dispone de estos recursos, como en grandes empresas tecnológicas o en el campo de la investigación científica. Sin embargo, su capacidad para generalizar en escenarios con menos datos o en contextos que difieren de los datos de entrenamiento sigue siendo un desafío abierto. A pesar de ello, la innovación en arquitecturas de redes neuronales y técnicas de optimización ha permitido avances importantes en el rendimiento y la eficiencia de los modelos de aprendizaje profundo [14].



### **2.5.1. Redes Neuronales Profundas**

### **2.5.2. Redes Neuronales Convolucionales**

# 3

## Conclusions and Futures Lines of Research

### 3.1. Conclusions

### 3.2. Future lines of Research



# 4

## Conclusiones y Líneas Futuras

### 4.1. Conclusiones

### 4.2. Líneas Futuras



# Referencias

- [1] Techopedia. “¿Qué es la inteligencia artificial?” En: (2024). Accedido el 7 de octubre de 2024. URL: <https://www.techopedia.com/definition/1905/artificial-intelligence-ai>.
- [2] Wikipedia. “Inteligencia artificial”. En: (2024). Accedido el 7 de octubre de 2024. URL: [https://es.wikipedia.org/wiki/Inteligencia\\_artificial](https://es.wikipedia.org/wiki/Inteligencia_artificial).
- [3] Salesforce. “Comprender la inteligencia artificial: definición, tipos, casos de uso y desafíos”. En: (2021). Accedido el 7 de octubre de 2024. URL: <https://www.salesforce.com/es/blogs/2021/01/ai-healthcare.html>.
- [4] TechCrunch. “The impact of AI on healthcare”. En: (2021). Accedido el 7 de octubre de 2024. URL: <https://techcrunch.com/2021/06/12/the-impact-of-ai-on-healthcare/>.
- [5] *Diagrama sobre Inteligencia Artificial y Machine Learning*. Imagen recuperada de DuckDuckGo. 2020. URL: <https://www.duacode.com/data/blog/106/images/215/4.jpg?t=20201112>.
- [6] E. Alpaydin. *Introduction to Machine Learning*. 4th. MIT Press, 2020. URL: <https://mitpress.mit.edu/9780262033848/introduction-to-machine-learning/>.
- [7] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006. URL: <https://www.springer.com/gp/book/9780387310732>.
- [8] T. M. Mitchell. *Machine Learning*. McGraw-Hill, 1997. URL: <https://www.cs.cmu.edu/~tom/10701/slides/mitchell-ml-book-1997.pdf>.
- [9] J. D. Kelleher y B. Tierney. *Data Science: A Practical Introduction to Data Science*. M4W Press, 2018. URL: <https://www.m4wpress.com/books/data-science-a-practical-introduction-to-data-science>.
- [10] Imagen sin autor. *Aprendizaje Supervisado vs No Supervisado*. Accedido el 7 de octubre de 2024. 2024. URL: [https://lh3.googleusercontent.com/-q3LXeJu275Q/YEzXbCDgc\\_I/AAAAAAAAxN0/mFU2-qIuuEcQpxaMTTnUOMCn4vZ4or\\_eQCLcBGAsYHQ/w640-h254/image.png](https://lh3.googleusercontent.com/-q3LXeJu275Q/YEzXbCDgc_I/AAAAAAAAxN0/mFU2-qIuuEcQpxaMTTnUOMCn4vZ4or_eQCLcBGAsYHQ/w640-h254/image.png).

- [11] Aaron Courville Ian Goodfellow Yoshua Bengio. *Deep Learning*. MIT Press, 2016.
- [12] Yann LeCun y Geoffrey Bengio Yoshua y Hinton. *Deep Learning*. doi:10.1038/nature14539. 2015.
- [13] Geoffrey Hinton. *A Practical Guide to Training Restricted Boltzmann Machines*. Accedido el 7 de octubre de 2024. 2012. URL: <https://www.cs.toronto.edu/~hinton/absps/guideTR.pdf>.
- [14] Alex Krizhevsky, Ilya Sutskever y Geoffrey Hinton. *ImageNet Classification with Deep Convolutional Neural Networks*. Accedido el 7 de octubre de 2024. 2012. URL: <https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf>.

# Apéndice A

## **Manual de Instalación**





UNIVERSIDAD  
DE MÁLAGA

| **uma.es**

E.T.S. DE INGENIERÍA INFORMÁTICA

E.T.S de Ingeniería Informática  
Bulevar Louis Pasteur, 35  
Campus de Teatinos  
29071 Málaga